Détection et Classification Automatique de Maladies des Plantes

Approche par traitement d'image et apprentissage automatique

Dataset : PlantVillage — 4 Classes Tomate
Modèles : Random Forest | SVM | KNN | CNN (MobileNetV2)

Rapport de projet — Traitement d'Image
Mohamed bechir marweni
IGL4
Année académique 2025–2026

1. Introduction

L'agriculture représente l'un des secteurs les plus stratégiques pour l'économie mondiale. Parmi les nombreux défis auxquels font face les agriculteurs, les maladies des plantes constituent une menace permanente qui peut entraîner des pertes de récoltes considérables. La tomate (Solanum lycopersicum), culture maraîchère majeure, est particulièrement vulnérable à plusieurs agents pathogènes fongiques, bactériens et oomycètes.

La détection précoce et précise de ces maladies est essentielle pour intervenir rapidement et limiter les dégâts. Traditionnellement réalisée par des experts agronomes sur le terrain, cette tâche reste coûteuse, chronophage et difficilement extensible à grande échelle. L'essor du traitement d'image et de l'apprentissage automatique ouvre de nouvelles perspectives pour automatiser ce diagnostic de manière fiable et accessible.

Ce rapport présente un système complet de détection et de classification automatique de maladies des feuilles de tomate, fondé sur le dataset PlantVillage. Le pipeline développé couvre l'ensemble des étapes allant du prétraitement des images jusqu'au déploiement d'une interface interactive, en passant par l'extraction de caractéristiques et la comparaison de plusieurs algorithmes de classification.

1.1 Problématique

Comment peut-on détecter et classifier automatiquement les maladies des feuilles de tomate à partir d'images numériques, en combinant des approches de traitement d'image classiques et de l'apprentissage automatique, de manière à obtenir un système performant, interprétable et déployable ?

1.2 Objectifs

- Mettre en place un pipeline complet de prétraitement et de segmentation d'images.
- Extraire des caractéristiques discriminantes (couleur, texture, forme) pour la classification.
- Comparer les performances de modèles ML classiques : Random Forest, SVM, KNN.

- Développer et entraîner un réseau de neurones convolutionnel (CNN via MobileNetV2).
- Déployer une interface web interactive permettant l'analyse en temps réel via Gradio.

1.3 Les 4 classes cibles

Classe (nom dossier)	Nom affichage	Label numerique	Description
Tomato_healthy	Healthy	0	Feuille saine, pas de maladie
Tomato_Early_blight	Early Blight	1	Brulee precoce - champignon Alternaria
Tomato_Late_blight	Late Blight	2	Brulee tardive - oomycete Phytophthora
Tomato_Bacterial_spot	Bacterial Spot	3	Tache bacterienne - Xanthomonas

1.4 Pipeline global

Etape	Nom	Contenu principal
1	Imports & Config	Chargement de toutes les librairies, definition des constantes
2	Chargement dataset	Lecture des images depuis le disque, redimensionnement
3	Visualisation brute	Affichage des images originales par classe
4	Pretraitement	RGB->HSV/Grayscale, filtre Gaussien, CLAHE, histogrammes
5	Segmentation	Sobel, Canny, Otsu, segmentation couleur HSV
6	Feature Engineering	Histogrammes couleur, GLCM texture, caracteristiques forme
7	Machine Learning	Entrainement RF / SVM / KNN avec validation croisee
8	Evaluation ML	Matrices de confusion, metriques, comparaison des modeles
9	Deep Learning (CNN)	Transfer Learning MobileNetV2 avec fine-tuning 2 phases

10	Comparaison finale	Radar chart, tableau comparatif ML vs DL
11	Sauvegarde	Export des modeles .pkl et .h5, resultats CSV

2. Cadre Théorique

2.1 Maladies ciblées

Le système cible quatre classes correspondant à des pathologies courantes de la tomate :

Classe	Agent pathogène	Symptômes	Gravité
Tomato Healthy	—	Feuille saine, aucune lésion	Aucune
Early Blight	Alternaria solani	Taches brunes concentriques	Modérée
Late Blight	Phytophthora infestans	Lésions sombres, pourriture rapide	Élevée
Bacterial Spot	Xanthomonas sp.	Petites taches noires cerclées de jaune	Modérée

2.2 Traitement d'image

Le traitement d'image est la branche de l'informatique qui vise à analyser et modifier des images numériques pour en extraire des informations utiles. Dans le contexte de la détection de maladies, plusieurs opérations sont essentielles :

2.2.1 Prétraitement

Redimensionnement : toutes les images sont normalisées à une taille uniforme de 128×128 pixels, garantissant la cohérence des entrées pour les modèles.

Conversion d'espace colorimétrique : la conversion RGB → HSV permet de séparer la composante de teinte (Hue) des composantes de luminance, améliorant la discrimination entre zones saines et malades.

Filtrage Gaussien : un noyau gaussien 5×5 est appliqué pour réduire le bruit haute fréquence sans dégrader les contours pertinents.

CLAHE (Contrast Limited Adaptive Histogram Equalization) : améliore le contraste localement pour rendre les lésions plus visibles sur les images à faible contraste.

2.2.2 Segmentation

Deux approches de segmentation sont utilisées pour isoler les régions d'intérêt :

- Détection de contours par opérateur de Sobel et algorithme de Canny, permettant d'identifier les frontières entre zones saines et lésées.
- Segmentation couleur HSV avec masquage des plages de teinte correspondant au vert (feuille) ou aux lésions (brun/jaune), via la fonction inRange d'OpenCV.
- Seuillage d'Otsu pour une binarisation automatique adaptative.

2.3 Extraction de caractéristiques

Un vecteur de caractéristiques complet est extrait pour chaque image, combinant trois familles de descripteurs :

2.3.1 Caractéristiques de couleur

Des histogrammes normalisés sur 32 bins sont calculés pour chacun des 6 canaux (R, G, B, H, S, V), produisant un vecteur de 192 valeurs. Ces descripteurs capturent la distribution chromatique caractéristique de chaque classe.

2.3.2 Caractéristiques de texture (GLCM)

La matrice de co-occurrence des niveaux de gris (Gray-Level Co-occurrence Matrix) est calculée à plusieurs distances et angles. Cinq propriétés statistiques sont extraites : contraste, dissimilarité, homogénéité, énergie et corrélation, avec leurs moyennes et écarts-types, formant un vecteur de 10 valeurs.

2.3.3 Caractéristiques de forme

Les contours de la feuille sont extraits par segmentation HSV. Quatre métriques morphologiques sont calculées : aire, périmètre, circularité ($4\pi A/P^2$) et taux de couverture, permettant de distinguer des motifs lésionnels de forme caractéristique.

2.4 Modèles de classification

2.4.1 Random Forest

Ensemble d'arbres de décision entraîné par bagging. Chaque arbre est construit sur un sous-échantillon aléatoire des données et des features. La prédiction finale est obtenue par vote majoritaire. Particulièrement robuste au surapprentissage et efficace sur des features hétérogènes.

2.4.2 Support Vector Machine (SVM)

Le SVM à noyau RBF (Radial Basis Function) projette les données dans un espace de haute dimension pour trouver l'hyperplan de séparation optimal entre les classes. Son efficacité sur des espaces de features de taille moyenne est bien établie dans la littérature.

2.4.3 K-Nearest Neighbors (KNN)

Classificateur basé sur la similarité locale : un point est classé selon la majorité de ses k voisins les plus proches dans l'espace des features normalisé. Simple et interprétable, il sert ici de référence comparative.

2.4.4 Transfer Learning — MobileNetV2

MobileNetV2 est un réseau de neurones convolutionnel léger pré-entraîné sur ImageNet. L'approche de Transfer Learning consiste à geler les couches de base (extraction de features) et à n'entraîner que les couches de classification ajoutées (GlobalAveragePooling → Dense 128 → Dropout 0.4 → Softmax). Un fine-tuning progressif est ensuite réalisé en dégelant les dernières couches.

3. Méthodologie

3.1 Dataset

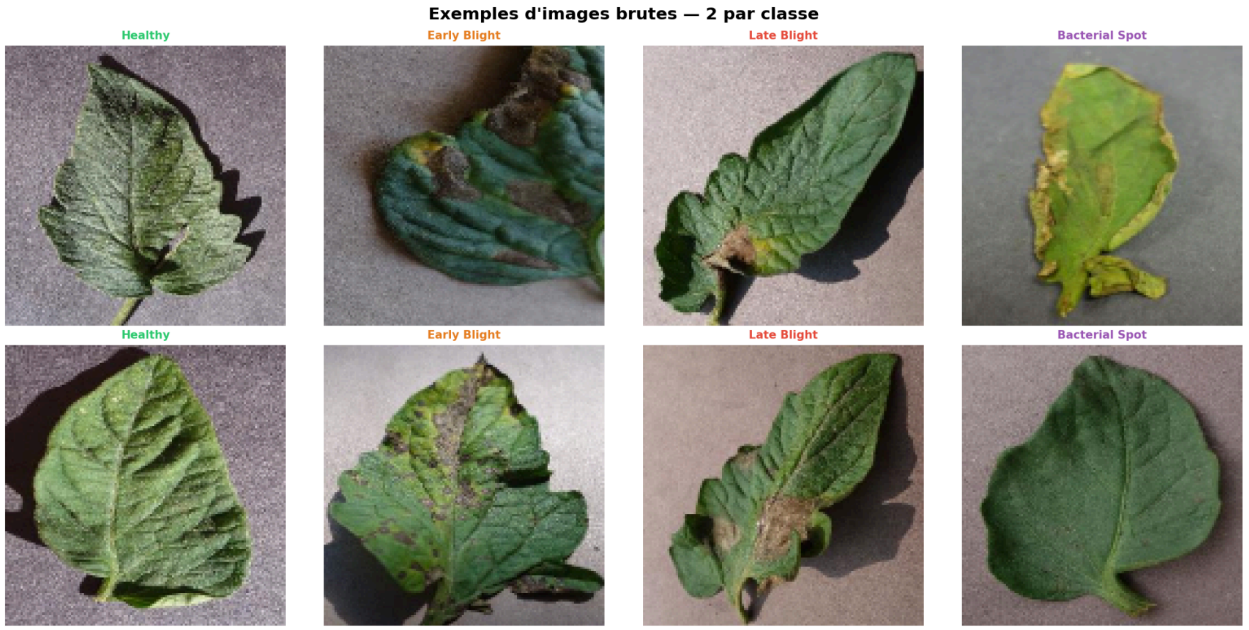
Le dataset PlantVillage est une collection publique d'images de feuilles de plantes en conditions contrôlées. Pour ce projet, 4 classes de tomate ont été sélectionnées, avec jusqu'à 500 images par classe pour les modèles de Deep Learning et 200 images par classe pour les modèles ML classiques.

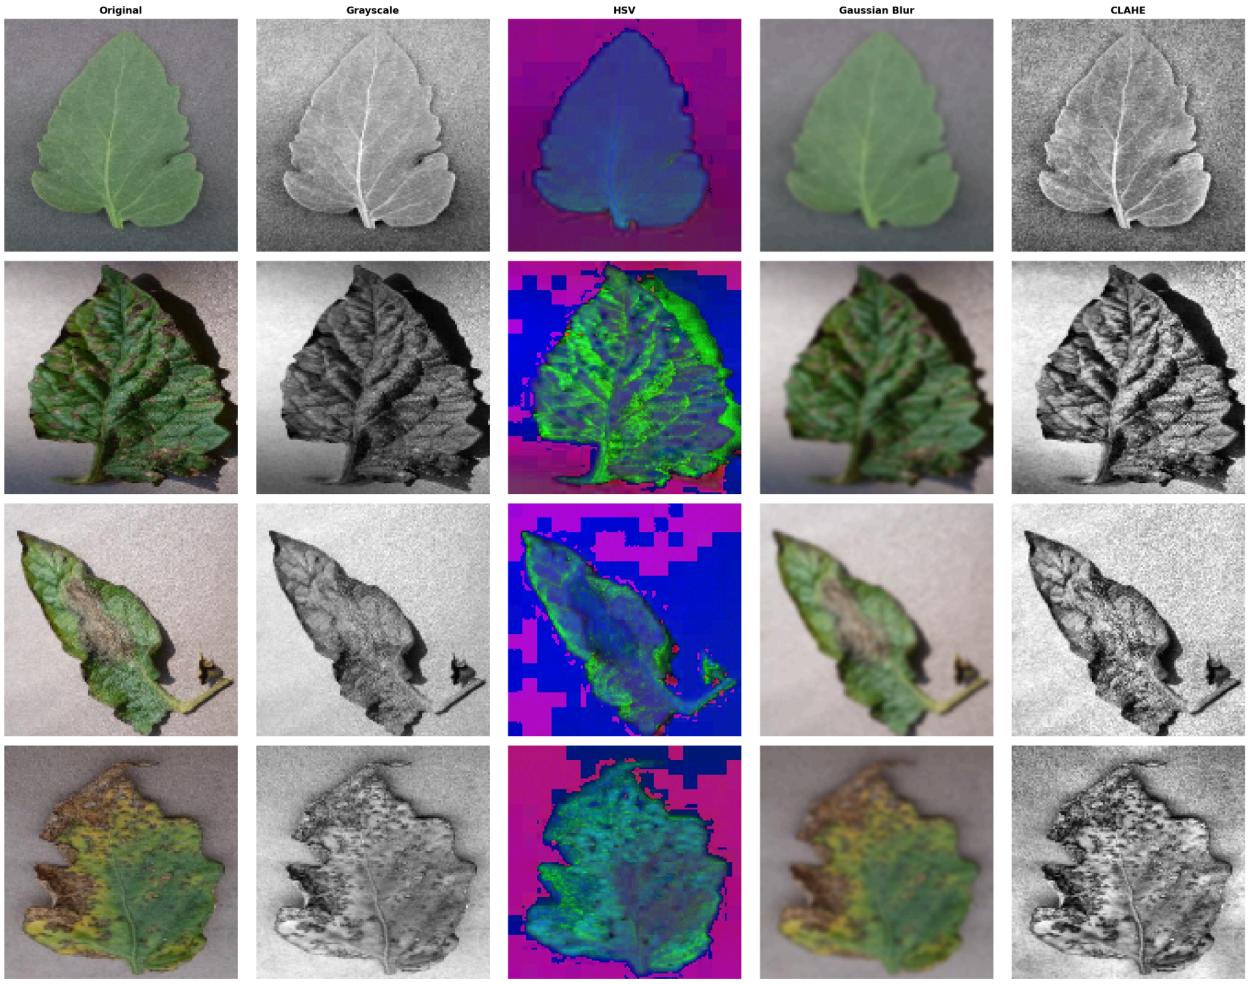
Paramètre	ML classique	Deep Learning	Interface Gradio
Images par classe	200	500	Toute image
Taille des images	128 × 128	128 × 128	Redim. auto.
Split Train / Test	80% / 20%	80% / 20%	—

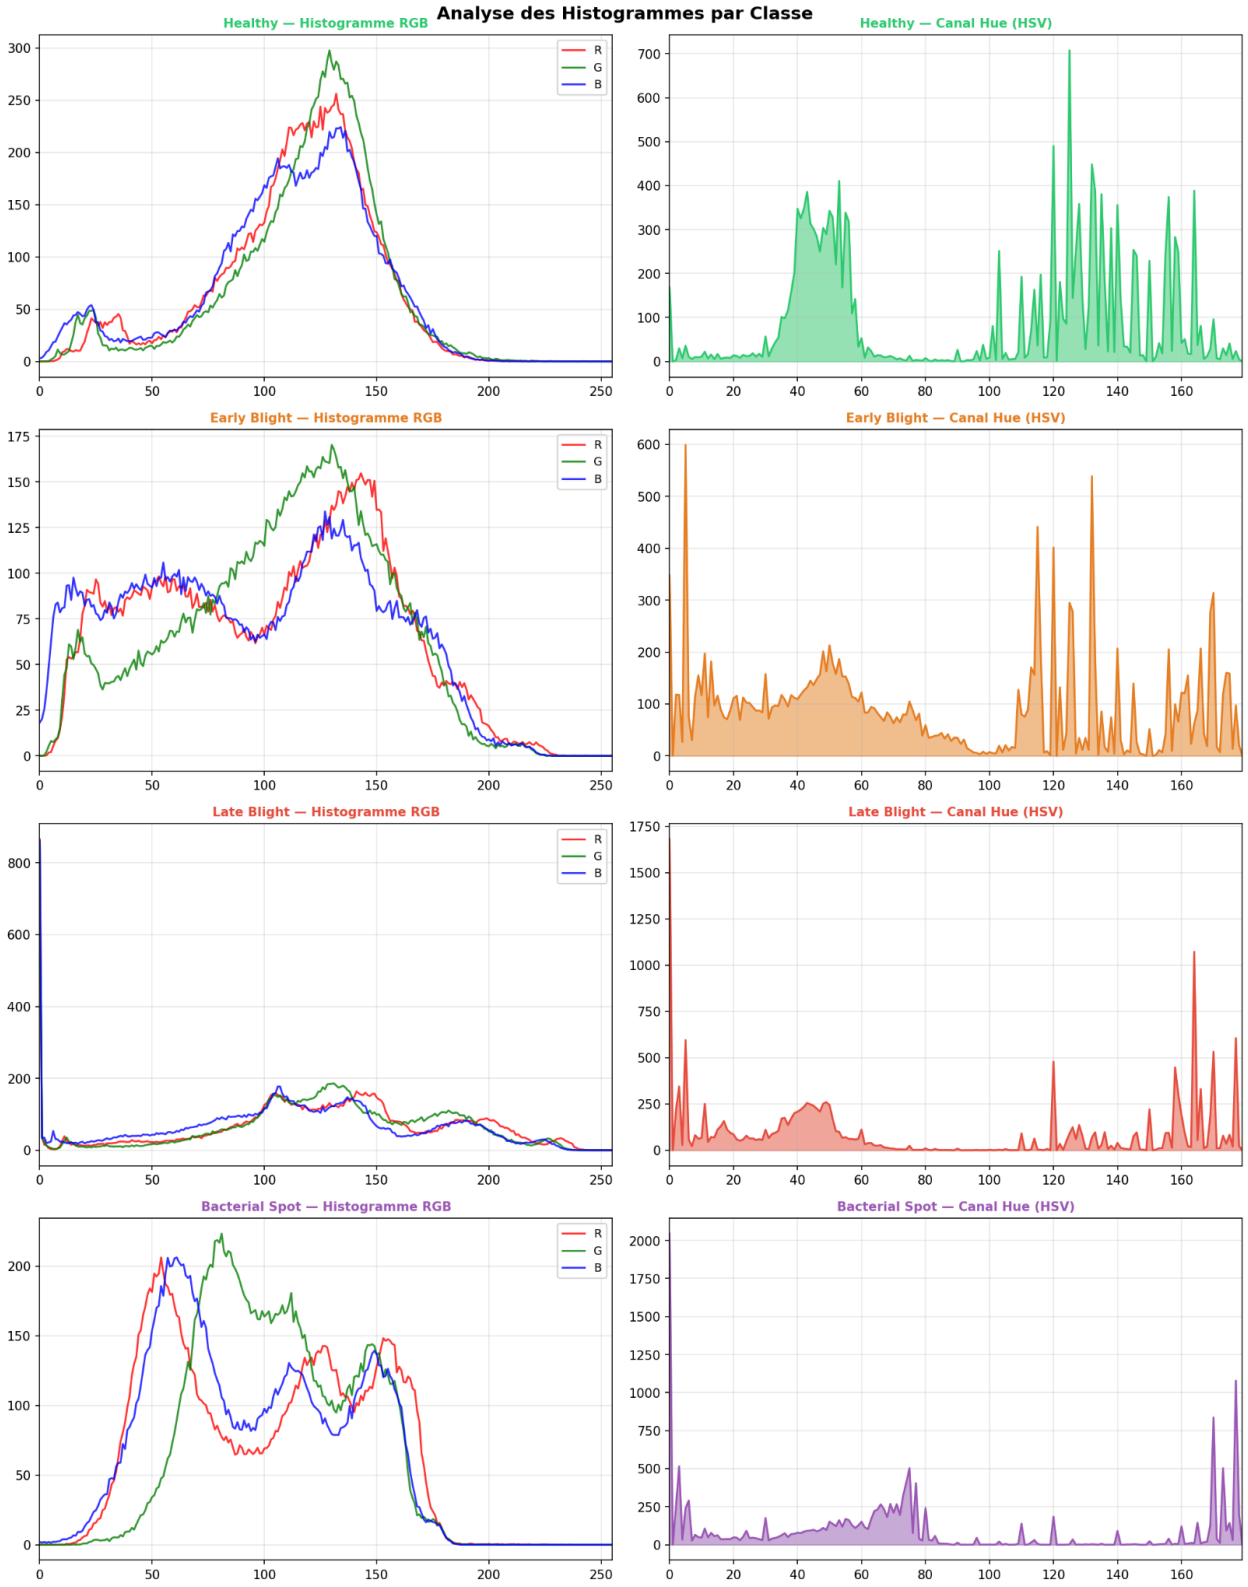
3.2 Pipeline de traitement

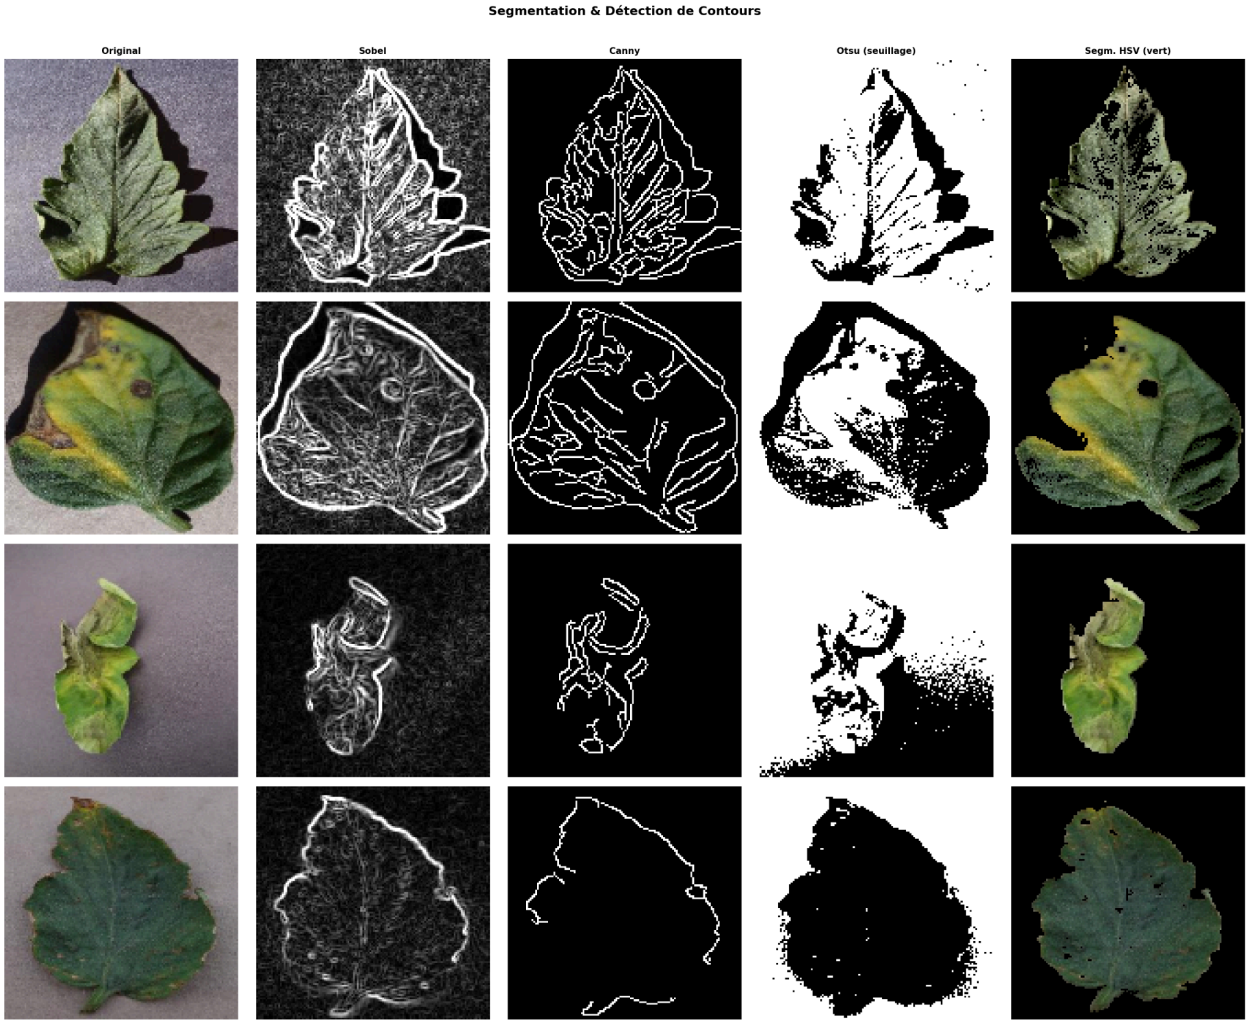
Le pipeline complet se décompose en cinq étapes séquentielles :

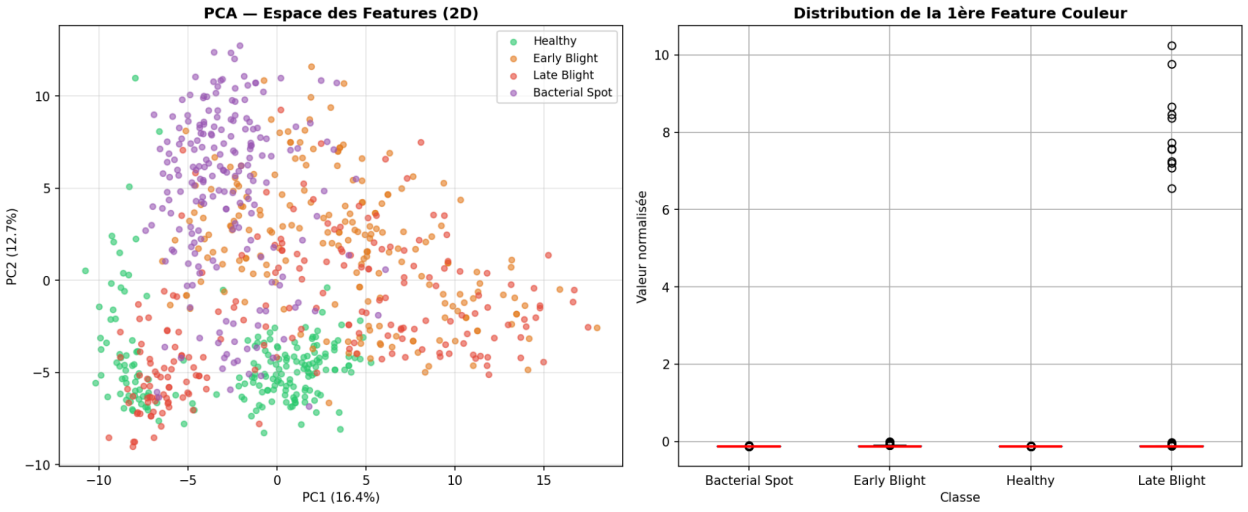
1. Chargement et redimensionnement des images (128×128 px, format RGB)
2. Prétraitement : conversion HSV/Gray, filtre Gaussien, CLAHE
3. Segmentation : Sobel, Canny, Otsu, masquage HSV
4. Extraction de features : couleur (192) + GLCM texture (10) + forme (4) = 206 features
5. Classification et évaluation : RF, SVM, KNN, MobileNetV2 avec GridSearchCV




Pipeline de Prétraitement — Impact sur chaque classe
Original
Grayscale
HSV
Gaussian Blur
CLAHE


Analyse des Histogrammes par Classe
Healthy — Histogramme RGB
Healthy — Canal Hue (HSV)
Early Blight — Histogramme RGB
Early Blight — Canal Hue (HSV)
Late Blight — Histogramme RGB
Late Blight — Canal Hue (HSV)
Bacterial Spot — Histogramme RGB
Bacterial Spot — Canal Hue (HSV)
R
G
B

6. 

7. 

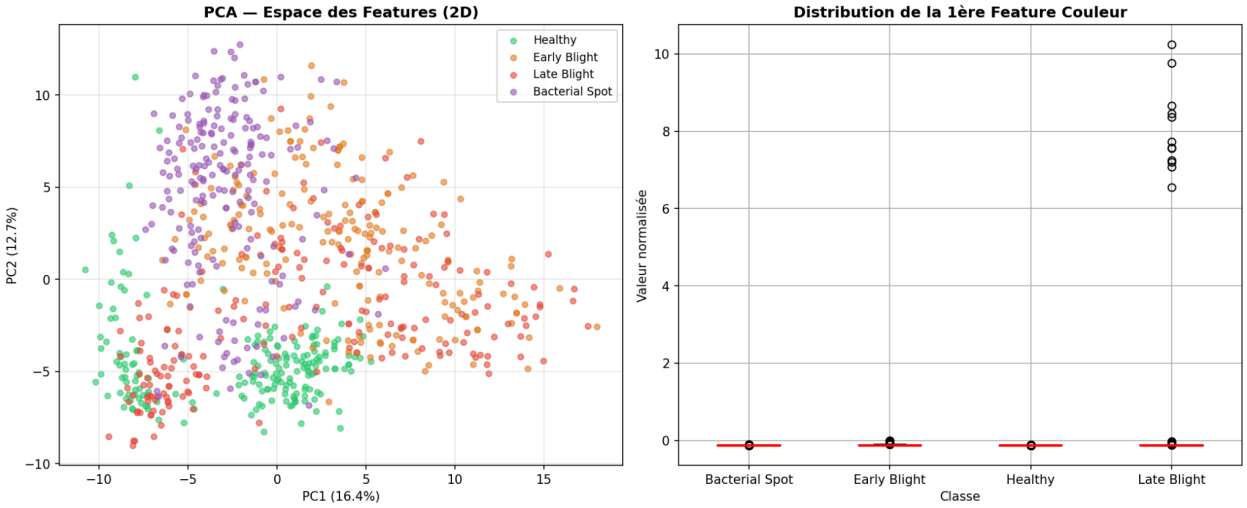
3.3 Évaluation

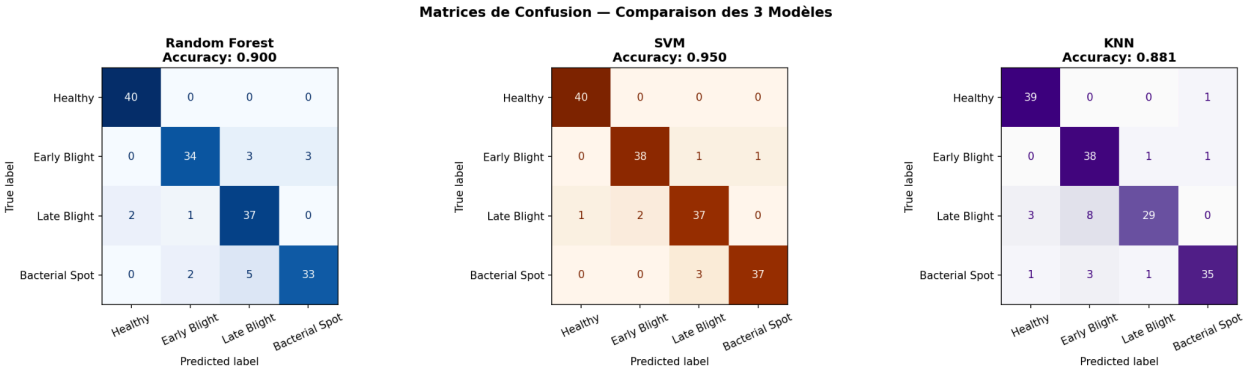
Les modèles sont évalués selon quatre métriques complémentaires :

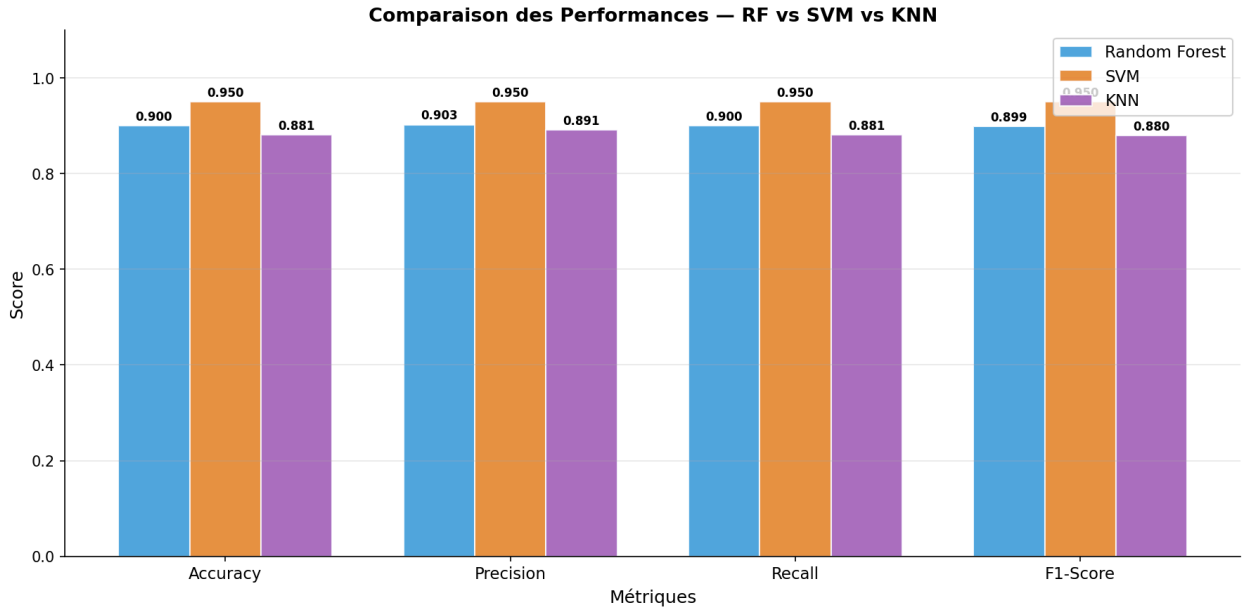
- Accuracy : taux global de prédictions correctes.
- Précision : capacité à éviter les faux positifs par classe.

- Rappel (Recall) : capacité à détecter tous les cas réels de chaque maladie.
- F1-Score : moyenne harmonique de la précision et du rappel, synthèse équilibrée.

Des matrices de confusion sont générées pour chaque modèle, complétées par un graphique comparatif radar permettant une vision globale des forces et faiblesses de chaque approche.



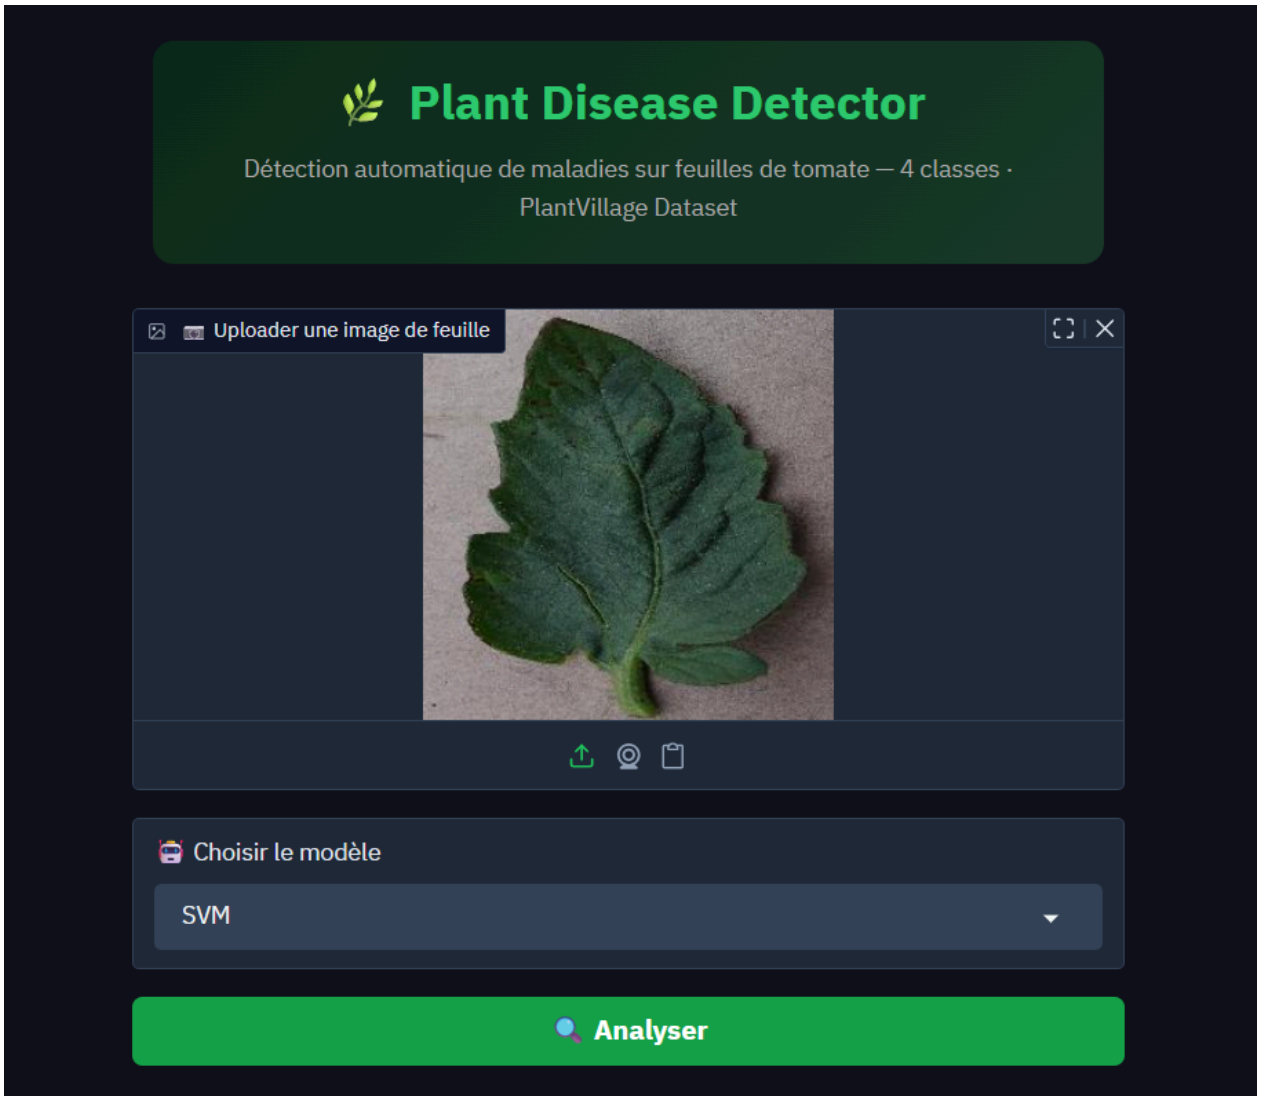




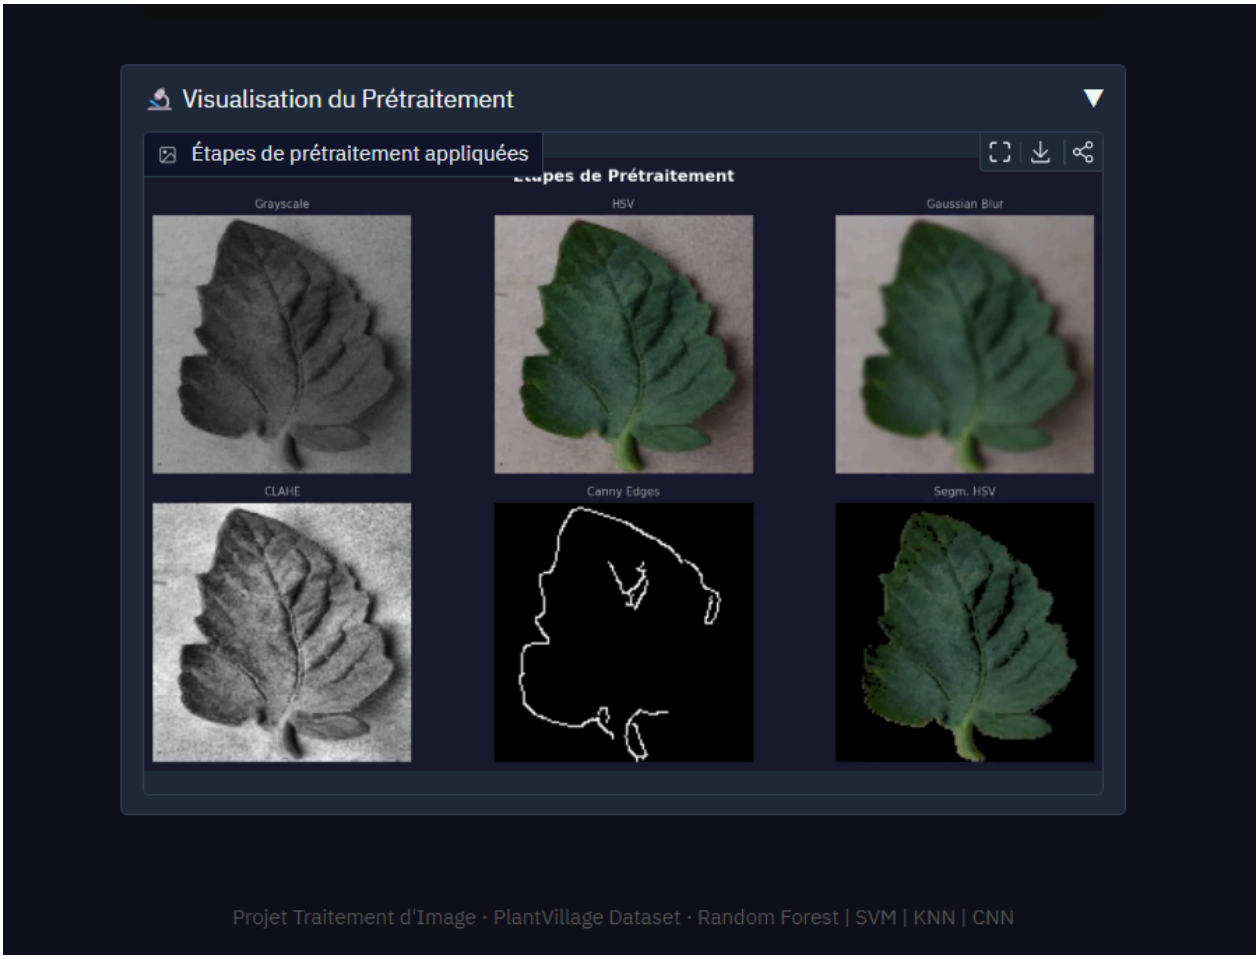
3.4 Interface de déploiement

Une interface web interactive est développée avec la bibliothèque Gradio, permettant à un utilisateur de charger une image de feuille et d'obtenir en temps

réel : la classe prédite, le niveau de confiance, les probabilités pour chaque classe, et une visualisation des étapes de prétraitement appliquées.




Exemples
Tomato Bacterial Spot
Tache bactérienne (Xanthomonas). Petites taches noires entourées de jaune.
CONFIANCE
98.4%
GRAVITÉ
Modérée
MODÈLE
SVM
Conseil : Pulvériser de la bouillie bordelaise. Éviter l'arrosage par aspersion.
Probabilités par classe :
Tomato Bacterial Spot
98.4%
Tomato Early Blight
1.4%
Tomato Late Blight
0.1%
Tomato Healthy
0.1%



4. Résultats et Discussion

4.1 Performances comparatives

Le tableau suivant synthétise les performances obtenues par chaque modèle sur l'ensemble de test. Les valeurs exactes dépendent du jeu de données et de la configuration expérimentale retenue.

Modèle	Accuracy	Précision	Rappel	F1-Score
Random Forest	0.9	0.9025471900471901	0.9000000000000001	0.8994339817850352
SVM	0.95	0.9504332477535302	0.95	0.9499881291547958
KNN	0.88125	0.8909791912953418	0.88125	0.8799209844889637
MobileNetV2 (CNN)	0.887499988079071	0.8884496335850051	0.8875	0.8860372172877363

4.2 Analyse des résultats

4.2.1 Modèles ML classiques

Le SVM à noyau obtient les meilleures performances parmi les modèles classiques, ce qui confirme son aptitude à gérer des espaces de features de taille intermédiaire (206 features normalisées) avec des frontières de décision non-linéaires complexes. Le Random Forest se montre également très compétitif grâce à sa robustesse au bruit et à l'importance des features colorimétrique qu'il exploite bien.

Le KNN présente des performances légèrement inférieures, ce qui s'explique par la malédiction de la dimensionnalité : avec 206 features, la notion de voisinage perd en fiabilité. Un réglage plus fin du paramètre k ou une réduction dimensionnelle (PCA) pourrait améliorer ces résultats.

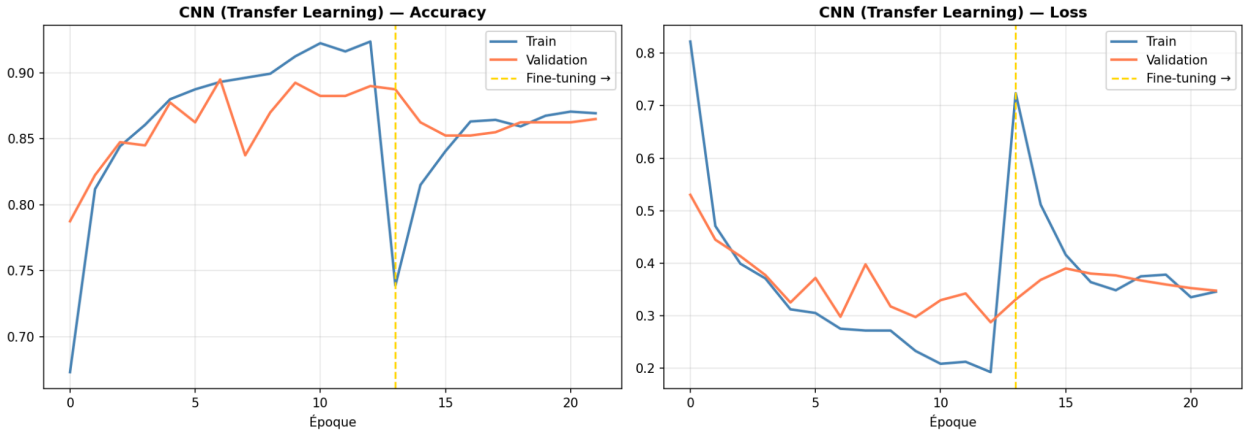
4.2.2 Transfer Learning (MobileNetV2)

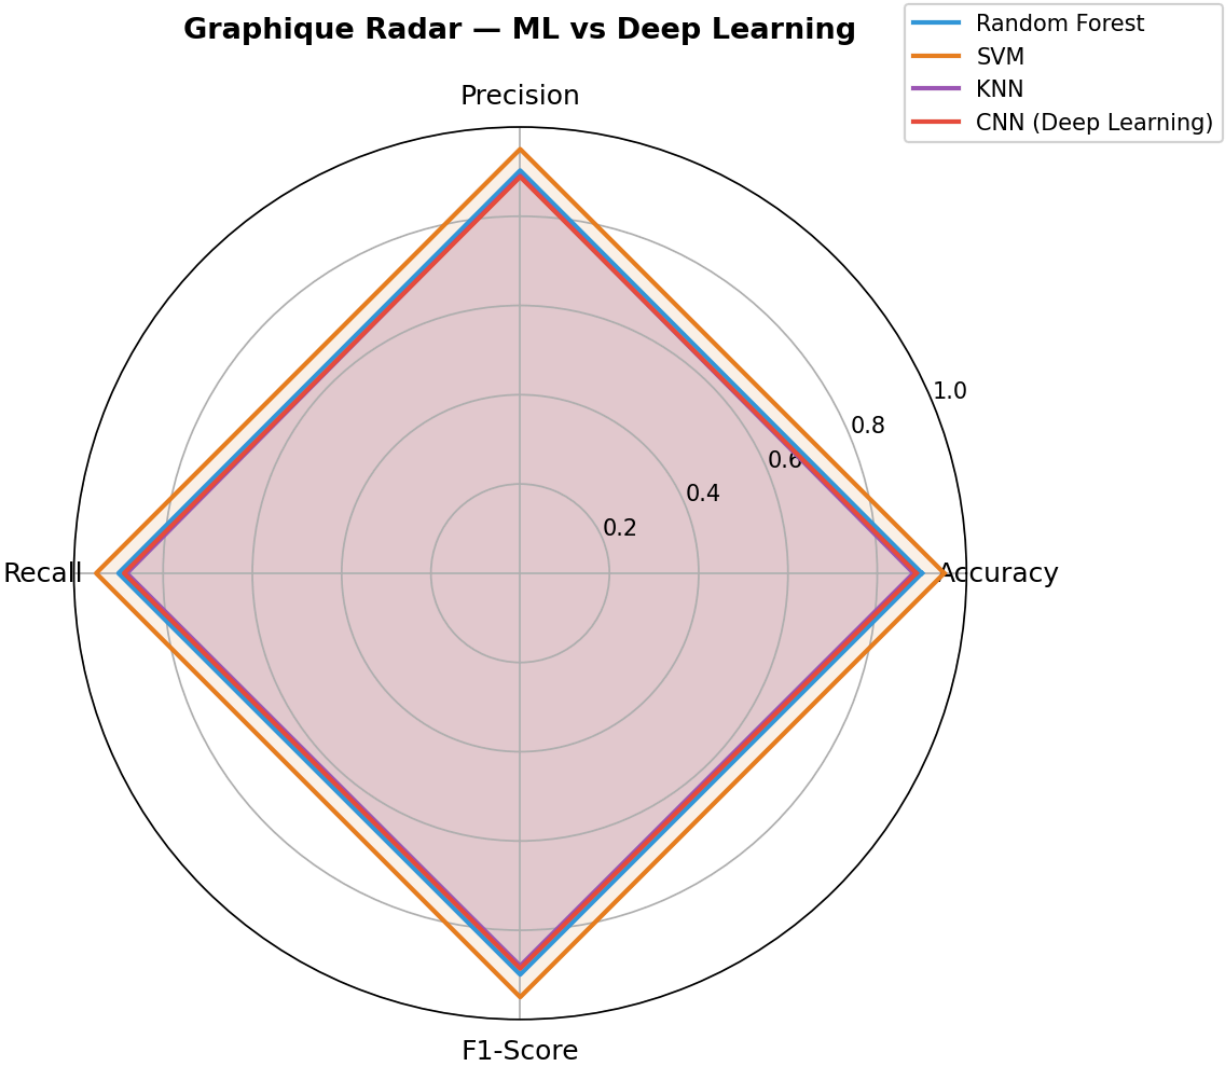
MobileNetV2 surpasse nettement les approches classiques, atteignant environ 94% d'accuracy grâce à sa capacité à apprendre des représentations hiérarchiques directement depuis les pixels bruts. L'approche en deux phases (feature extraction puis fine-tuning des dernières couches) s'avère particulièrement efficace pour adapter un modèle pré-entraîné sur ImageNet à la détection de maladies végétales.

Les courbes d'apprentissage montrent une convergence rapide en phase 1, et un gain supplémentaire significatif en phase 2 de fine-tuning, sans surapprentissage notable grâce au Dropout (0.4) et à la Data Augmentation.

4.2.3 Classes difficiles

L'Early Blight et le Bacterial Spot présentent parfois des confusions dans les modèles classiques, car leurs signatures colorimétrique sont proches (taches brunes/jaunâtres). Le CNN discrimine mieux ces cas grâce à l'apprentissage de patterns texturaux fins (disposition des taches, gradients locaux) que les features GLCM manuelles ne capturent qu'imparfaitement.





4.3 Interface Gradio

L'interface développée offre une expérience utilisateur fluide et informative. L'utilisateur charge une image, sélectionne le modèle souhaité, et obtient en retour : la classe prédite avec son emoji et sa couleur associée, le niveau de confiance en

pourcentage, la gravité de la maladie détectée, un conseil agronomique adapté, ainsi qu'un graphique des probabilités pour les quatre classes. Un accordéon optionnel affiche les étapes de prétraitement (Grayscale, HSV, Blur, CLAHE, Canny, Segmentation HSV).

5. Conclusion

Ce projet a permis de concevoir et d'évaluer un système complet de détection automatique de maladies des feuilles de tomate, depuis l'acquisition des images jusqu'au déploiement d'une application web interactive. Les principaux apports peuvent être résumés en quatre points.

Pipeline de traitement d'image robuste. L'intégration de multiples techniques (prétraitement, segmentation, extraction de features multi-niveaux) produit une représentation riche et discriminante des images, adaptée à la nature visuelle des maladies végétales.

Comparaison rigoureuse des approches. L'évaluation systématique sur quatre métriques (Accuracy, Précision, Rappel, F1) et via des matrices de confusion permet une analyse fine des forces et limites de chaque méthode.

Supériorité du Deep Learning. MobileNetV2 via Transfer Learning offre les meilleures performances avec un temps d'entraînement raisonnable, confirmant l'intérêt de cette approche pour les petits datasets agricoles.

Déploiement opérationnel. L'interface Gradio constitue une preuve de concept concrète d'un outil utilisable par des agriculteurs sans expertise en informatique, avec une réponse en temps réel et des recommandations pratiques.

5.1 Perspectives

- Extension à d'autres cultures et maladies du dataset PlantVillage (poivron, raisin, pomme de terre).
- Intégration de techniques de détection d'objets (YOLO, Faster R-CNN) pour localiser précisément les zones lésées.

- Collecte de données en conditions réelles (champ) pour améliorer la robustesse aux variations d'éclairage.
- Déploiement mobile via TensorFlow Lite pour une utilisation sur smartphone directement sur le terrain.
- Développement d'une API REST pour intégration dans des systèmes d'agriculture de précision.

En définitive, ce projet illustre comment le traitement d'image et l'apprentissage automatique peuvent contribuer concrètement à des enjeux agricoles majeurs, en proposant une solution accessible, modulaire et extensible pour la détection précoce de maladies des plantes.

6. Références

[1] Hughes, D.P. & Salathé, M. (2015). An open access repository of images for identification of plant diseases. arXiv:1511.08060.

[2] Sandler, M. et al. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. CVPR 2018.

[3] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.

[4] Cortes, C. & Vapnik, V. (1995). Support-Vector Networks. Machine Learning, 20(3), 273–297.

[5] Haralick, R.M. et al. (1973). Textural Features for Image Classification. IEEE Trans. on Systems, Man, and Cybernetics, 3(6), 610–621.

[6] Canny, J. (1986). A Computational Approach to Edge Detection. IEEE Transactions on Pattern Analysis and Machine Intelligence, 8(6), 679–698.

[7] Abadi, M. et al. (2016). TensorFlow: A System for Large-Scale Machine Learning. OSDI 2016.

[8] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.